

Projektpräsentation – automatisierte Analyse von Mundart-Chatnachrichten

12.12.2025 | Raphael Weis

1. Ausgangslage – Projektstand bei Zwischenpräsentation

Idee

Automatisierte **Sentiment-Analyse** für Schweizerdeutsche Chatnachrichten.

Verwendete Modelle

- **BoW + Logistic Regression**
→ mit Dialekt-Preprocessing
- **TF-IDF + Logistic Regression**
→ Uni- und Bigramme, Preprocessing
- **SBERT + Logistic Regression**
→ paraphrase-multilingual-MiniLM-L12-v2

Herausforderungen

- Chatnachrichten sind **wenig** und **extrem kurz** (oft 2–5 Wörter)
- **Kein Kontext** → Sentiment sehr schwer zu bestimmen (vor allem für Embedding-Modelle)
- **Hohe Accuracy**, aber künstlich verzerrt
→ Modelle erkennen triviale Muster (z.B. einzelne Token, Emojis), dadurch **schlechte Generalisierbarkeit** (Overfitting)
- Fehlende Vielfalt im Training (wenig Variationen)

2. Erweiterung & Optimierung des Projekts

2.1 Datenerweiterung und Analyse

- **Generierung zusätzlicher Mundartnachrichten mit mehr Kontext**
→ komplexere Sätze → bessere Modellrobustheit
- **Kein Einsatz von Emojis**
Begründung: Emojis sind extrem starke Sentimentmarker → Modelle lernen „Emoji = Sentiment“ statt semantische Inhalte → schlechte Generalisierung.
- **Mehr Daten- und Modell-Analysen:** z.B. Confusion Matrix und Zipf-Analyse

2.2 Einführung einer mehrstufigen Klassifikation

Sentiment mit Unterklassen (Intents)	Vorteile
<ul style="list-style-type: none">• Positiv → <i>Dankbarkeit, Freude & gute Laune ...</i>• Negativ → <i>Stress & Überforderung, Traurigkeit ...</i>• Neutral → <i>Smalltalk, Organisation & Abmachungen ...</i>	<ul style="list-style-type: none">• Erhöhte semantische Differenzierung• bessere Auswertbarkeit und kontextsensitiver Chat-Antwortoptionen

2.3 Neue Modelle / Methoden

a) Next-Word-Prediction mittels N-Gramm Language Model

- Unterstützung beim Generieren von Text
- Nutzung eines 1-, 2-, 3-Gramm-Modells mit Backoff-Strategie
- "Welches Wort ist wahrscheinlich als nächstes?"

b) Predict Answer (SBERT-Embedding Retrieval)

- semantisch ähnliche Nutzeranfragen finden
- passende Antwort aus vordefiniertem Antwortkorpus auswählen

inkl. Debug-Ansicht


- erklärt, welche Nachbarn ähnlich sind und welche Ähnlichkeitswerte vergeben wurden → wichtig für Interpretierbarkeit

Warum Retrieval und kein generatives Modell?

- Zu kleine Datenmenge: für generative Modelle viel grössere Daten nötig
- Funktionsfähigkeit: schnell und stabil bei klar definierten Intents und Standardantworten
- Erklärbarkeit: Mit SBERT-Nachbarn sieht man transparent, warum eine Antwort gewählt wurde.

2.4 Integration in Streamlit-App (Frontend)

<https://mundartchat.streamlit.app>

 **Modelle & Datengrundlage**

💬 Anzahl Chatnachrichten: 900

> 😊 Sentiment (3) & Intents (18)

> 🗨️ Standardantworten (Defaults)

> 💻 Verwendete Modelle

> 🔍 Modell-Performance (Testset)

> 📊 Label-Verteilung

> 📏 Textlängen (Tokens)

> 📄 Token-Statistik

> 📈 Zipf-Analyse (Token-Verteilung)

> 🧩 N-Gramm-Statistik (LM)

> 📄 Projektpräsentation (PDF)

Mundart-Chat Demo

Sentiment, Next-Word, Antwort-Retrieval für Schweizerdeutsch-Chat

Mundart-Nachricht eingeben

z.B. «ich ha kei bock meh uf dä stress»

Sentiment-Klassifikation Next-Word Vorschlag Antwortvorschlag Debug Nachbarn

Next-Word Vorschläge berechnen

3. Pipeline – Gesamtprozess

1 Datengrundlage

- 900 Sätze (manuell + generiert)
- Chatpairs (User-Text-Antwort-Paare) als Grundlage für das SBERT-basierte Antwort-Retrieval

2 Preprocessing

- Dialektstandardisierung
- Lowercasing
- Tokenisierung auf Wortebene
- Entfernung von Stoppzeichen / Noise-Token

3 Feature Engineering & Modelltraining

BoW (Bag-of-Words): **CountVectorizer** und Klassifikation via multinomiale **Logistic Regression**

TF-IDF: **TfidfVectorizer** und Klassifikation via multinomiale **Logistic Regression**

SBERT: **SentenceTransformer** und multinomiale **Logistic Regression** auf Embedding-Raum

3 Neu: N-Gramm Language Model

- Training von 1-, 2-, 3-Grammen
- Backoff-Strategie für Next-Word-Vorhersagen
- Nutzung in der App zur Unterstützung der Texteingabe

3 Neu: Antwort-Retrieval (SBERT-basiert)

- Suche nach semantisch ähnlichster Chatnachricht und Auswahl der passenden Antwort
- Debug-Ansicht für „Nearest Neighbors“

4 Evaluations & Visualisierungen in der App

- Accuracy, Precision, Recall, F1
- Confusion Matrices (Heatmaps) für SBERT
- Label-Verteilung
- Token-Statistik, N-Gramm-Statistik
- Zipf-Analyse
- Kosinus-Ähnlichkeit

4. Fazit – Optimierte Lösung und Verbesserungspotential

Erreichte Optimierungen

- etwas bessere Generalisierbarkeit und robustere Modelle für kurze Dialekttexte
- mehr semantische Tiefe dank Intent-Klassen
- mehr Transparenz durch Debugging
- Demo-App für Sentimentanalyse, Next-Word, Antwortvorschläge

Verbesserungspotenzial

- grössere & vielfältigere Datengrundlage (mehr Dialektvarianten, "natürliches" Chatmaterial)
- mehr Kontextverarbeitung (z.B. Dialogmodelle)
- Erweiterung der Intents und Multi-Label-Klassifikation
- Kombination aus Retrieval und leichter Generierung (RAG)